

Rapport Projet MMPose

Sylvain Fraresso, Thomas Saurel,
Gaël Jean-Albert, Titouan Martineau

I. Introduction

Notre projet consiste en l'estimation de pose des mains dans le cadre de la pratique du piano. Notre objectif est donc de pouvoir analyser des photos ou vidéos de mains jouant du piano afin de déterminer la position et l'agencement de la main : phalanges, poignet etc. Ces résultats pourraient être utilisés de diverses manières, par exemple pour reconstituer les notes jouées dans un contexte bruyant ou sans le son, là où un modèle analysant l'audio ne serait d'aucune utilité. On pourrait aussi imaginer des applications comme l'animation 3D où de telles technologies permettraient de reproduire des gestes techniques comme la pratique du piano sans recourir à des dispositifs comme la motion capture.

II. Méthodologie (outils et données)

Dans cette optique, nous avons opté pour un modèle de la librairie MMPose dans la section « Hand 2D Keypoints », HRNetV2 (High Resolution Net), une architecture de réseau de neurones convolutif. Après avoir essayé différents poids pour le modèle issus des différents datasets d'entraînement disponibles, nous avons choisi d'utiliser les poids correspondant au dataset COCO-WholeBody-Hand car il donnait les résultats les plus précis pour nos données.

Étant donné que le modèle que nous utilisons pour placer les keypoints des mains est entraîné pour fonctionner sur des images sur lesquelles la main compose la majorité de l'image, il nous fallait trouver un moyen d'isoler les mains dans un premier temps afin de fournir au modèle des données exploitables. Pour ce faire, nous avons utilisé un modèle de la suite Mediapipe, Hand Landmarker, nous permettant de détecter la position des mains dans l'image et de les isoler pour qu'elles puissent être traitées par MMPose.


Les données que nous cherchons à traiter sont des photos ou vidéos montrant un clavier de piano et entre une et deux mains posées dessus et jouant, la caméra est située exactement au-dessus du clavier, on observe donc les mains vues de haut avec le dos de la main face à la caméra, entre 3 et 5 octaves apparaissent à l'image, la caméra est fixe. Toutes les images et vidéos sont captées avec cette prise de vue.

III. Résultats et visualisations

En suivant cette méthodologie, nous avons obtenu des résultats relativement concluants. Le modèle place les 21 keypoints (4 pour chaque doigt et 1 pour le poignet) de manière adéquate sur les mains comme on peut l'observer sur l'exemple suivant, sur des photos de bonnes qualités dans des bonnes conditions lumineuses :




Inférence



Le rectangle vert encadrant la main correspond à la prédiction faite par le modèle de Mediapipe qui détecte la main et l'isole, on passe alors l'image d'origine accompagnée des coordonnées décrivant ce rectangle à MMPose qui réalise l'inférence en ne considérant que ce rectangle et pas l'image dans sa globalité. Les points rouges correspondent aux keypoints détectés par MMPose et indiquant la position des doigts et la base du poignet. Les lignes bleues, enfin, ne correspondent pas à une prédiction mais relient simplement les keypoints pour mieux visualiser la pose estimée de la main.

On peut également obtenir à partir des coordonnées des keypoints les trajectoires et vitesses des keypoints sur une vidéo. Par exemple, sur la vidéo de la gamme de do majeur à la main droite, on obtient les données suivantes pour le keypoint 0 correspondant au poignet :



IV. Discussions et pistes d'amélioration

En l'état actuel des choses, notre modèle MMPose couplé à Mediapipe permet de placer avec une précision satisfaisante les keypoints sur les images et vidéos lorsque celles-ci sont bien éclairées et avec une résolution suffisante. Cependant, il arrive que le modèle fasse des prédictions imprécises notamment dans des mauvaises conditions lumineuses (image trop sombre), sur des frames trop floues ou lorsque des doigts sont cachés par une partie de la main. Cela constitue un réel problème car il est très courant au piano qu'une partie de la main passe par-dessus un doigt et enregistrer des vidéos de bonne qualité et minimisant le flou de mouvement requiert beaucoup de mémoire.

Bien que l'on puisse estimer la pose des mains avec une certaine précision sur une vidéo, il ne semble pas possible, avec notre approche actuelle, de reconstituer les notes jouées à partir de l'image seule. En effet, on manque encore de précision sur le placement des keypoints et, même en supposant que les keypoints sont placés correctement, on peut pour autant très difficilement déterminer lorsqu'une touche est enfoncée ou non. Cette problématique pourrait nous amener à considérer la possibilité d'utiliser un modèle d'estimation de pose en 3D, cela nous permettrait, en supposant que la caméra est fixe de déterminer lorsqu'une touche est enfoncée à partir de la profondeur prédite pour la dernière phalange d'un doigt. Le problème de précision en revanche ne semble pas être résoluble par des ajustements du modèle mais plutôt par des ajustements des données à traiter.